

NG Travel

Optimisation de la performance commerciale Analyse & pilotage Yield Management

Tour-opérateur spécialisé sur la Grèce (Rhodes, Crète, Corfou, Grèce continentale, Thessalonique) —
18 627 réservations sur deux saisons (2025-2026).

Rapport de synthèse du projet

Cas pratique — Yield Management

1. Contexte et chiffres clés

Le projet couvre l'intégralité de la chaîne de valeur data : de la base de ventes brute (fichier Excel) jusqu'à un tableau de bord interactif déployé en ligne, en passant par un pipeline ETL structuré et un ensemble de systèmes de recommandation. L'objectif métier : identifier les leviers de rentabilité pour NG Travel et outiller les équipes Yield au quotidien.

CA brut total

63,1 M EUR

Marge nette

6,4 M EUR

Taux de marge

10,1 %

Dossiers déficitaires

28,0 %

18 627 dossiers de réservation sur deux saisons (2025-2026), pour 48 823 passagers, sur 5 destinations grecques (Rhodes, Crète, Corfou, Grèce continentale, Thessalonique). Le taux de marge global, mince (environ 10 %), et la proportion élevée de dossiers vendus à perte (28 %) sont le cœur du problème à résoudre.

2. Architecture technique

Le projet suit une architecture ETL classique en trois zones, séparée de l'application de visualisation :

```
Source .xlsx --[Extraction]--> Data Lake --[Transformation]--> DataFrame (mémoire) --[Load]--> Data Warehouse (.parquet) --[publication]--> data/ --> Application Streamlit
```

Organisation en packages Python

- **etl/** Extraction, transformation et chargement, un package dédié par étape :
extraction/Extraction.py (localise et copie la source), transformation/Transformation.py (nettoyage + 41 variables dérivées), load/Load.py (écriture dans le Data Warehouse).
- **pipeline_etl/** Orchestrateur qui enchaîne les trois étapes en mémoire, sans écriture disque intermédiaire.
- **data_preparation/** Variante autonome (Extraction + Transformation + Load en un seul script) pour une préparation rapide.
- **streamlit_app.py / utils.py** Point d'entrée Streamlit et fonctions partagées (chargement, filtres, formatage, agrégateur de performance unique).
- **pages/** 8 pages d'analyse, une page = un fichier, numérotées pour l'ordre du menu.

Les trois zones de données

Dossier	Contenu	Versionné	Rôle
Data Lake/	Base brute (.xlsx)	Non	Zone d'atterrissage locale du pipeline
Data Warehouse/	Base transformée (.parquet)	Non	Zone raffinée locale du pipeline

Dossier	Contenu	Versionné	Rôle
data/	Copie publiée de la base	Oui	Base lue par l'application, en local et en ligne

Cette séparation garantit que l'application déployée sur Streamlit Cloud reste fonctionnelle : les zones brute et raffinée sont ignorées par Git (données générées, reproductibles), seule la copie publiée dans data/ est versionnée.

3. Traitement et enrichissement des données

La base source contient 17 colonnes brutes (référence dossier, dates, réseau, passagers, aéroports, destination, nuitées, chiffre d'affaires, compagnie, achats prévisionnels, commission, marge). L'étape de transformation porte ce nombre à 41 colonnes, en conservant intégralement les données d'origine et en ajoutant des variables de calcul, de catégorisation et de contrôle qualité.

Nettoyage

- Colonnes renommées en snake_case explicite (ex. « BRUT TTC » devient ca_brut_ttc).
- Typage strict : dates, entiers (passagers, nuitées), flottants (montants financiers).
- Textes nettoyés (espaces superflus), valeurs manquantes étiquetées « NON RENSEIGNÉ » plutôt que supprimées.
- Codes aéroports et compagnies aériennes traduits en libellés lisibles (dictionnaires de correspondance).

Contrôle qualité (sans suppression de données)

- Cohérence comptable vérifiée : marge nette comparée à (CA brut - achats - commission), écart calculé et signalé.
- Un indicateur booléen « valide » isole les dossiers exploitables pour les KPI (CA positif, passagers positifs, nuitées positives, délai cohérent, dates renseignées) sans jamais supprimer de ligne : l'utilisateur peut inclure ou exclure ces dossiers via un filtre dans l'application.

Variables dérivées les plus importantes

Variable	Calcul / logique
nb_pax	adultes + enfants
delai_resa_jours	date_depart - date_resa
tranche_delai	Catégorie du délai : Last minute, Court, Moyen, Long, Très anticipé
tranche_duree	Catégorie des nuitées : Court séjour, Semaine, Long séjour
type_produit	destination + tranche_duree (clé d'analyse produit)
saison_touristique	Intensité touristique du mois de départ (Haute / Épaule / Basse / Hors saison)
marge_pct	marge_nette / ca_brut_ttc
taux_commission	commission / ca_brut_ttc
taux_achat	achats_prev / ca_brut_ttc (indicateur de coût fournisseur)
prix_moyen_pax	ca_brut_ttc / nb_pax
dossier_deficitaire	marge_nette négative

4. KPIs et pages de l'application Streamlit

Toutes les pages partagent les mêmes filtres (saison, destination, canal, intensité de saison) et un agrégateur de performance unique (perf_par), garantissant des indicateurs strictement cohérents d'une page à l'autre : dossiers, CA, marge, commission, prix moyen par passager, pourcentage de dossiers déficitaires, taux de marge, taux de commission, marge par dossier.

Page	Contenu principal / visualisations
Accueil	KPI globaux (CA, marge, taux de marge, déficit, passagers, panier moyen) + CA par destination et marge par canal (graphiques en barres).
Évolution temporelle	Courbes mensuelles (mesure et axe temporel au choix) + comparaison superposée 2025 vs 2026.
Performance par destination	Tableau de synthèse, graphiques CA et taux de marge, quadrant « pouvoir de prix » (nuage de points), heatmap destination x saison.
Performance par réseau	Vue par canal (B2B/B2C/Groupes), classement des réseaux créateurs et destructeurs de valeur, nuage de points marge vs commission (utilité).
Performance par axe	Vues dédiées ville de départ et délai de réservation, sélecteur d'axe libre, croisement configurable de deux dimensions (heatmap).
Outil Yield	Segments à risque, opportunités de hausse de prix, simulateur de repricing avec élasticité paramétrable.
Système de recommandation	4 recommandateurs interactifs (détail section 5).
Copilote IA	Résumé en langage naturel de chaque page, généré à la demande via l'API Mistral.
Bonus	Liste justifiée des données supplémentaires qui enrichiraient l'analyse.

Types de visualisations utilisées

- Graphiques en barres (horizontales ou verticales) pour les classements par dimension (CA, marge, taux de marge).
- Nuages de points (scatter) pour les analyses bi-variées : pouvoir de prix (marge % vs volume), utilité réseau (marge vs commission).
- Heatmaps (matrices croisées) pour visualiser deux dimensions simultanément (destination x saison, axe x axe configurable).
- Courbes temporelles avec superposition pour comparer les saisons à stade équivalent.
- Tableaux formatés (devises et pourcentages à la française) pour le détail chiffré.

5. Systèmes de recommandation

Quatre recommandateurs indépendants, tous fondés sur un principe commun : comparer une entité (réseau, segment, hôtel, compagnie) à des pairs similaires ou déjà performants, plutôt que d'appliquer une règle uniforme.

1. Réseau vers produit (filtrage collaboratif)

Construction d'une matrice réseau x produit (part du chiffre d'affaires par type de produit), calcul de similarité cosinus entre réseaux à partir de leur profil de vente. Pour un réseau donné, identification des produits sous-représentés par rapport à ses pairs les plus similaires, filtrés pour ne retenir que des produits déjà rentables ailleurs dans le portefeuille.

2. Prix cible par segment (benchmarking)

Pour un produit donné, comparaison de ses sous-segments (canal x délai de réservation) entre eux. Les sous-segments sains (marge supérieure ou égale à 5 %, déficit inférieur ou égal à 30 %) les plus chers servent de référence pour proposer un prix cible aux sous-segments sous-performants du même produit.

3 et 4. Hôtels et compagnies aériennes de substitution

Pour une destination donnée, identification de l'hôtel ou de la compagnie au ratio coût/marge le moins favorable, avec proposition d'alternatives mieux négociées dans la même destination et estimation du gain potentiel si le volume était transféré.

Chaque recommandation est accompagnée d'une mise en garde explicite sur les hypothèses simplificatrices retenues (volumes supposés transférables, coût hôtel et vol non dissociés dans les achats), pour un usage en aide à la décision et non comme prévision automatique.

6. Copilote IA — Intelligence artificielle (API Mistral)

La page Copilote IA intègre une brique d'intelligence artificielle générative : chaque page du tableau de bord est représentée par un bouton, et un clic déclenche la génération d'un résumé en langage naturel, rédigé par un modèle de langage à partir des indicateurs clés calculés en temps réel sur le périmètre filtré par l'utilisateur.

- Modèle utilisé : mistral-large-latest, via le SDK officiel Python (mistralai).
- Chaque page dispose de sa propre fonction de synthèse des chiffres clés, transmise au modèle avec une consigne de rédaction professionnelle en français.
- Fonctionnalité optionnelle : sans clé API configurée, le reste de l'application continue de fonctionner normalement (boutons désactivés, message explicatif).
- Clé API gérée via un fichier secrets.toml exclu du dépôt Git (jamais versionné), avec configuration équivalente sur Streamlit Cloud pour le déploiement en ligne.

7. Design, expérience utilisateur et bonnes pratiques

Thème visuel

Palette « Méditerranée / Grèce » (bleu Égée, blanc, tons chauds) appliquée à l'ensemble de l'application, avec une couleur distincte pour chaque page du menu latéral, facilitant le repérage visuel.

Import et export de données

- Import d'un fichier brut par l'utilisateur : le pipeline de transformation s'exécute en mémoire (même logique que l'ETL), sans écriture sur le serveur, compatible avec un déploiement en ligne.
- Export de la base nettoyée en .csv et .xlsx directement depuis le navigateur.

Qualité et fiabilité du code

- Chaque évolution vérifiée par des tests automatisés (streamlit.testing.v1.AppTest) sur les données réelles avant mise en ligne.
- Gestion stricte des secrets : clé API et fichiers de données brutes ou intermédiaires exclus du contrôle de version (.gitignore).
- Architecture ETL en packages Python testables indépendamment de l'application.

8. Limites et pistes d'amélioration

- La saison 2026 est encore en cours de remplissage : les comparaisons avec 2025 doivent se lire à stade équivalent.
- Le simulateur de prix et les prix cibles reposent sur une élasticité non mesurée et des hypothèses de transfert de volume simplifiées : des plafonds théoriques à valider avant toute décision tarifaire.
- Le coût d'achat (ACHATS PREV) regroupe hébergement et transport aérien sans distinction, ce qui limite la précision des recommandations par compagnie aérienne.
- Données complémentaires qui affinaient l'analyse : historique des prix, taux d'occupation hôtelière, prix des concurrents, coûts aériens dans le temps, budget marketing par réseau, statut d'annulation.